

Полный отчёт: MCP-сервер расписания, выбор инструментов и агентные петли

Дата: 9 октября 2026 года. Домен: учебное расписание. Проект: D:/lesson-02-mcp-demo/mcp-demo.

1. Результат и границы отчёта


Реализованы четыре инструмента `schedule_*` на Python SDK MCP с протоколом 2026-07-28, явным `handle` снимка, двумя форматами ответа, закрытыми схемами и исправимыми ошибками. Сохранены реальные проверки `pytest` и MCP Inspector. Эксперименты выполнены локальной Qwen/Qwen3-0.6B: 720 решений о выборе инструмента и 180 агентных эпизодов. Числа взяты из сохранённых результатов, а не из моделируемых или ожидаемых исходов.

При N=100 вариант с полным каталогом дал точность 43,3%, с поиском top-5 — 0%: поиск не включил правильный инструмент ни для одного из 30 запросов. В части B все три условия дали 48,3% успеха и 0 наблюдавшихся петель. Модель завершала эпизод после одного вызова; этот эксперимент не позволяет установить преимущество `guard` над исправлением ответа инструмента.

Материалы лекции с реализацией `LoopGuard` не предоставлены. Использован явно описанный `guard` с окном 6 и двумя критериями из задания. Совпадение с точным кодом лекции не подтверждено. Исходный материал ДЗ 1 также не приложен; домен сохранён по имеющемуся проекту расписания. Данные расписания синтетические, а не действующее расписание учреждения.

1.1. График точности от N с интервалами

Выбор инструмента: Qwen3-0.6B
95%-е интервалы: bootstrap по 30 запросам, по 3 повтора



Точки — средняя точность по 30 запросам × 3 повтора; вертикальные отрезки — 95%-е percentile bootstrap интервалы, 10 000 выборок **запросов** с сохранением повторов. А — полный каталог, В — top-5 по эмбедингам. При N=5 точки и интервалы совпадают, поэтому линия В перекрывает А. При N=100 для В наблюдаемая точность и bootstrap интервал равны 0%; это не доказывает нулевую точность на новых запросах. Соединяющие линии служат только для чтения четырёх измеренных значений N.

График отдельно: PNG, SVG для экспорта.

1.2. Таблица входных токенов на запрос

Вход LLM — среднее `usage.prompt_tokens` с учётом полного промпта и шаблона чата. Вход эмбединга — логический онлайн-расход кодирования пользовательского запроса; фактически эти векторы были заэкшированы. Сумма токенов разных моделей описывает объём запросов, а не денежную стоимость.

N	Условие	Вход LLM	Вход query embedding	Всего входных токенов
5	A	201,3	0,0	201,3
5	B	201,3	37,0	238,2
20	A	395,3	0,0	395,3
20	B	211,9	37,0	248,9
50	A	779,3	0,0	779,3
50	B	215,7	37,0	252,7
100	A	1396,3	0,0	1396,3
100	B	212,8	37,0	249,8

Построение индекса каталога однократно потребовало 1030 токенов embedding-модели. Оно не включено в расход каждого запроса. Размеры `concise/detailed` для трёх вызовов основного MCP-сервера приведены отдельно в разделе реализации.

1.3. Таблица петель для трёх условий

Каждое условие: 20 задач × 3 повтора = 60 эпизодов. Шаг — ответ модели, включая финальный. Токены — средний полный расход эпизода, включая повторно переданную историю. «Попытки» включают предлагаемый вызов, который guard мог бы остановить до исполнения.

Условие	Петли	Попытки петли	Средние шаги	Входные токены	Выходные токены	Всего токенов	Успех (95% CI)
Пустой ответ, без guard	0,0%	0,0%	2,00	510,0	67,2	577,3	48,3% (35,0–61,7%)
Пустой ответ + LoopGuard (окно 6)	0,0%	0,0%	2,00	510,1	67,7	577,8	48,3% (35,0–61,7%)
Ответ с подсказкой, без guard	0,0%	0,0%	2,00	525,5	64,2	589,8	48,3% (35,0–61,7%)

Во всех условиях: 29 успехов и 31 неподтверждённый финальный ответ; один исполненный вызов инструмента на эпизод. Guard ни разу не сработал; исправление ответа не вызвало повторного поиска. Эти наблюдения не устанавливают, что помогает сильнее. Указанный guard реализует критерии задания; точное соответствие реализации из лекции не подтверждено.

1.4. Три угрозы валидности

Состав и разметка выборки. Сто описаний и 30 запросов синтетические; пулы вложенные, используются одни и те же четыре целевых инструмента. Заранее заданная рубрика устраняет неоднозначность оценивания, но результат зависит от близких отвлекающих описаний и не характеризует произвольные публичные MCP-каталоги. Bootstrap оценивает вариацию запросов внутри этого набора и не учитывает неопределённость выбора самого каталога. Для проверки переноса нужен независимый набор реальных запросов и несколько каталогов.

Модель, язык и способ выбора. Проверена одна небольшая модель в Q8_0, русские запросы и преимущественно английские описания; выбор выполняется структурированным JSON-ответом, а не встроенным function calling. Это ограничивает перенос результата на другие модели, языки и интерфейсы. KV-кэш и особенности runtime допускают небольшие численные различия повторных запусков. Следует проверять несколько моделей и единый язык описаний отдельным экспериментом, не заменяя текущие результаты.

Отсутствие петель и непроверенный guard лекции. В baseline не было ни одной петли: модель после пустого результата завершала задачу неподтверждённым ответом. Поэтому эксперимент не содержит событий, по которым можно оценить предотвращение петель; 0–0 bootstrap интервал не подтверждает универсальную безопасность или равенство методов. Кроме того, guard с окном 6 восстановлен по критериям задания, поскольку код лекции не предоставлен. Для вывода о преимуществах нужен отдельно заявленный прогон с задачами и агентом, у которых возникают повторы, и с подтверждённой реализацией guard.

2. Соответствие требованиям

Требование	Реализация / результат	Доказательство
MCP 2026-07-28; stateless; server/discover; _meta	MCPServer, stdio, discovery без initialize; метаданные каждого запроса	server.py, client.py, artifacts/wire-log.json
Не меньше четырёх инструментов одного пространства имён	schedule_search, schedule_get, schedule_day, schedule_room	tools/list; приложение со схемами
enum, description, additionalProperties: false	Закрытые входные и выходные объекты; enum для закрытых множеств	Схемы tools/list и pytest
response_format и три примера размеров	concise / detailed; шесть измерений текста и полного результата	README.md, artifacts/token-counts.json
Ошибки как isError: true с подсказкой	code, message, hint; без стектрейса	Ошибки четырёх инструментов в Inspector
Состояние явным handle, без сессий	schedule_handle=schedule-v1; в нестабильном инструменте также fault_handle	Перезапуск процесса проверен тестом
pytest успех и ошибка каждого инструмента; Inspector	28 основных + 12 экспериментальных тестов; 9 запусков Inspector	pytest-all.xml и inspector-log.json
A: пул 100, ≥20 близких отвлекающих	4 целевых + 96 синтетических; 28 близких	Приложение A; tools.json
A: 30 размеченных запросов, N=5/20/50/100, 3 повтора, A/B	$30 \times 4 \times 3 \times 2 = 720$ решений	Приложение B; selection.jsonl
A: точность, Recall@5, входные токены, 95% bootstrap по запросам	Все метрики; 10 000 выборок кластеров по 30 запросов	Таблицы раздела экспериментов; summary.json
B: 50% пустых ответов, 20 задач × 3, без/c guard, окно 6	60 эпизодов на условие, парная маска отказов; guard по критериям задания	loops.jsonl; точный guard лекции не подтверждён
B: петли, шаги, токены, успех; подсказка и сравнение	Три условия, 180 эпизодов; победитель не установлен из-за отсутствия петель	Раздел B и ограничения

3. Реализация MCP и проверка сервера

Импорт сервера: `from mcp.server import MCPServer`; версия пакета `mcp==2.2.0`. Сервер читает неизменяемый снимок из четырёх записей. Инструменты имеют аннотации чтения и идемпотентности. Транспорт stdio не делает соединение источником доменного состояния.

entry_id	course	day	start–end	room	teacher
agents-mon	agents	monday	10:00–11:30	314	Anna Petrova
python-tue	python	tuesday	12:00–13:30	210	Ivan Smirnov
databases-wed	databases	wednesday	14:00–15:30	115	Maria Volkova

entry_id	course	day	start–end	room	teacher
agents-wed	agents	wednesday	10:00–11:30	314	Anna Petrova

Нижe приведена документация реализации, включая измерения размеров ответов и подтверждение Inspector. Она включена в отчёт целиком, чтобы эти пункты не требовали чтения отдельного README.

MCP: синтетическое расписание курсов

Домен сохранён из исходного примера ДЗ 1: расписание курсов. Все занятия, преподаватели и аудитории вымышлены. SDK mcp==2.2.0, импорт from mcp.server import MCPServer, протокол 2026-07-28, транспорт stdio.

Запуск

Обычный Python 3.13 на Windows:

```
py -3.13 -m venv .venv
.\.venv\Scripts\python.exe -m pip install -r requirements-lock.txt
.\.venv\Scripts\python.exe client.py
.\.venv\Scripts\python.exe -m pytest -q
.\.venv\Scripts\python.exe measure_tokens.py
```

requirements.txt задаёт основные зависимости; requirements-lock.txt фиксирует все версии проверенного окружения Windows/Python 3.13. При первом измерении tiktoken скачивает словарь cl100k_base. Сам сервер работает только с локальной неизменяемой фикстурой.

Контракт инструментов

Инструмент	Назначение	Обязательные аргументы
schedule_search	Фильтр по курсу и дню; all — без фильтра	schedule_handle
schedule_get	Занятие по идентификатору из поиска	schedule_handle, entry_id
schedule_day	Все занятия указанного дня	schedule_handle, day
schedule_room	Все занятия в аудитории	schedule_handle, room

Каждый инструмент принимает response_format: enum concise / detailed, по умолчанию concise. Входные и выходные объекты закрыты: additionalProperties: false, у всех полей есть description. Курсы, дни, аудитории и форматы объявлены через enum; строка аудитории "314" и число 314 различаются. entry_id — открытый идентификатор, его нужно получать из поиска. Источник истины для аргументов — tools/list.

concise возвращает id, day, start, room. detailed добавляет course, end, teacher, источник, часовой пояс и пояснение. Оба режима сохраняют schedule_handle и synthetic: true. Отсутствие совпадений при поиске — успешный ответ с пустым entries.

Stateless и discovery

Нет initialize, notifications/initialized и состояния сессий. server/discover реализует SDK; клиент вызывает его для проверки supportedVersions, затем tools/list и tools/call. Вызов инструмента до discovery тоже разрешён и проверен тестом.

Каждый запрос клиента содержит в params._meta:

```
{
  "io.modelcontextprotocol/protocolVersion": "2026-07-28",
  "io.modelcontextprotocol/clientInfo": {"name": "schedule-demo", "version": "1.0.0"},
  "io.modelcontextprotocol/clientCapabilities": {}
}
```

schedule_handle обязателен и равен schedule-v1: это handle неизменяемого снимка данных, а не идентификатор соединения. Нет скрытого «текущего расписания» и мутаций. Тот же handle работает после перезапуска процесса. Неизвестный или пропущенный handle возвращает ошибку, сервер не выбирает снимок за клиента. Пример полного обмена: artifacts/wire-log.json.

Ошибки

Ошибки инструментов возвращаются как результат tools/call с isError: true. Текстовый блок содержит JSON с code, message, hint. Например, schedule_get с несуществующим entry_id возвращает entry_not_found и совет выполнить schedule_search с тем же handle. Неверные типы, enum, лишние и отсутствующие поля получают invalid_arguments и подсказку свериться с tools/list. Неожиданные внутренние ошибки заменяются безопасным сообщением без стектрейса. Протокольные ошибки, например некорректный JSON-RPC, остаются ошибками протокола SDK.

Размер ответа в токенах

Измерено tiktoken==0.11.0, encoding cl100k_base. В каждой ячейке: **текст** content[0].text / **полный JSON результата** tools/call. Полный результат сериализован с ensure_ascii=False, separators=(",", ":"); включает текст, structuredContent и поля SDK, но не JSON-RPC оболочку id/jsonrpc/result. Это воспроизводимый подсчёт выбранным токенизатором, а не универсальная стоимость для любой модели. Текст и structuredContent содержат одинаковые данные, поэтому полный результат крупнее.

Общий аргумент всех примеров: schedule_handle="schedule-v1".

Пример	concise: текст / результат	detailed: текст / результат
schedule_search(course="agents")	57 / 167	118 / 288
schedule_get(entry_id="agents-mon")	36 / 123	81 / 212
schedule_day(day="wednesday")	59 / 171	121 / 294

Исходные ответы и измерения: artifacts/token-counts.json. Повторный подсчёт: python measure_tokens.py.

Проверки и MCP Inspector

`test_server.py` запускает реальный сервер отдельным процессом и проверяет через MCP: успех каждого инструмента в обоих форматах, ошибки каждого инструмента, неверные типы и enum, лишние поля, отсутствие `handle`, неизвестный инструмент, ненайденную запись, пустой поиск, входные/выходные схемы, `discovery`, `_meta`, вызов до `discovery` и `handle` после перезапуска.

Для Inspector нужен Node.js ≥ 22.19 . Проверяемая версия Inspector: 2.10.1.

```
npm install --prefix .inspector @modelcontextprotocol/inspector@2.10.1
.\.venv\Scripts\python.exe run_inspector.py --cli .inspector/node_modules/@modelcontextprotocol/inspector/clients/launcher/build/index.js
```

Скрипт запускает официальный Inspector CLI в режиме `--protocol-era modern`: каталог со строгой проверкой схем и успешный/ошибочный вызов всех четырёх инструментов. Для ошибки инструмента ожидается код завершения Inspector 5, для успеха — 0. Сохраняются полные команды, `stdout`, `stderr` и коды завершения в `artifacts/inspector-log.json`. JSON-RPC обмен нашего клиента хранится отдельно и не выдаётся за лог Inspector.

Проверено 9 октября 2026 года: **28 pytest-тестов прошли**, отчёт `artifacts/pytest-results.xml`; **все 9 запусков Inspector прошли** (каталог + 4 успеха + 4 ожидаемые ошибки), стектрейсов в логе нет. Окружение: Windows, Python 3.13.7, MCP SDK 2.2.0, Node.js 22.20.0, Inspector 2.10.1. Inspector получает аргументы через `--tool-args-json`, чтобы номер аудиторией оставался строкой.

Официальные источники

Эксперименты выбора из 100 инструментов и агентных петель находятся в `experiments/README.md`. Итоговые измерения с Qwen3-0.6B, Recall@5, токенами и бутстрэп-интервалами: `experiments/results/REPORT.md`.

[Спецификация MCP 2026-07-28](#)

[Изменения stateless, discovery и _meta](#)

[Python SDK v2](#)

[Inspector CLI: команды, modern mode и коды завершения](#)

3.1. Фактические протокольные сообщения

Первый запрос и ответ `discovery` из журнала реального клиента:

```
[
  {
    "request": {
      "jsonrpc": "2.0",
      "id": 1,
      "method": "server/discover",
      "params": {
        "_meta": {
          "io.modelcontextprotocol/protocolVersion": "2026-07-28",
          "io.modelcontextprotocol/clientInfo": {
```

```

        "name": "schedule-demo",
        "version": "1.0.0"
    },
    "io.modelcontextprotocol/clientCapabilities": {}
}
}
},
{
  "response": {
    "jsonrpc": "2.0",
    "id": 1,
    "result": {
      "cacheScope": "private",
      "capabilities": {
        "prompts": {
          "listChanged": true
        },
        "resources": {
          "listChanged": true,
          "subscribe": true
        },
        "tools": {
          "listChanged": true
        }
      },
      "resultType": "complete",
      "supportedVersions": [
        "2026-07-28"
      ],
      "ttlMs": 0,
      "_meta": {
        "io.modelcontextprotocol/serverInfo": {
          "name": "Course schedule",
          "version": "1.0.0"
        }
      }
    }
  }
}
}
]

```

Успешный вызов (запрос и ответ):

```

[
  {
    "request": {
      "jsonrpc": "2.0",
      "id": 3,
      "method": "tools/call",
      "params": {
        "name": "schedule_search",
        "arguments": {

```

```

    "schedule_handle": "schedule-v1",
    "course": "agents"
  },
  "_meta": {
    "io.modelcontextprotocol/protocolVersion": "2026-07-28",
    "io.modelcontextprotocol/clientInfo": {
      "name": "schedule-demo",
      "version": "1.0.0"
    },
    "io.modelcontextprotocol/clientCapabilities": {}
  }
}
},
{
  "response": {
    "jsonrpc": "2.0",
    "id": 3,
    "result": {
      "content": [
        {
          "text": "{\\\"schedule_handle\\\":\\\"schedule-v1\\\",\\\"synthetic\\\":true,\\\"entries\\\":[{\\\"id\\\":\\\"agents-mon\\\",\\\"day\\\":\\\"monday\\\",\\\"start\\\":\\\"10:00\\\",\\\"room\\\":\\\"314\\\"},{\\\"id\\\":\\\"agents-wed\\\",\\\"day\\\":\\\"wednesday\\\",\\\"start\\\":\\\"10:00\\\",\\\"room\\\":\\\"314\\\"}]}\",
          "type": "text"
        }
      ],
      "isError": false,
      "resultType": "complete",
      "structuredContent": {
        "schedule_handle": "schedule-v1",
        "synthetic": true,
        "entries": [
          {
            "id": "agents-mon",
            "day": "monday",
            "start": "10:00",
            "room": "314"
          },
          {
            "id": "agents-wed",
            "day": "wednesday",
            "start": "10:00",
            "room": "314"
          }
        ]
      }
    },
    "_meta": {
      "io.modelcontextprotocol/serverInfo": {
        "name": "Course schedule",
        "version": "1.0.0"
      }
    }
  }
}

```

```

    }
  }
}
]

```

Ошибка инструмента (запрос и ответ):

```

[
  {
    "request": {
      "jsonrpc": "2.0",
      "id": 4,
      "method": "tools/call",
      "params": {
        "name": "schedule_search",
        "arguments": {
          "schedule_handle": "invalid",
          "course": "agents"
        },
        "_meta": {
          "io.modelcontextprotocol/protocolVersion": "2026-07-28",
          "io.modelcontextprotocol/clientInfo": {
            "name": "schedule-demo",
            "version": "1.0.0"
          },
          "io.modelcontextprotocol/clientCapabilities": {}
        }
      }
    },
    "response": {
      "jsonrpc": "2.0",
      "id": 4,
      "result": {
        "content": [
          {
            "text": "{\n\"code\": \"invalid_arguments\\\", \"message\": \"Invalid fields: schedule_handle\\\", \"hint\": \"Use tools/list: supply required fields, enum values and correct types; remove extra fields.\\\"}\",\n\"type\": \"text\"\n}",
            "type": "text"
          }
        ],
        "isError": true,
        "resultType": "complete",
        "_meta": {
          "io.modelcontextprotocol/serverInfo": {
            "name": "Course schedule",
            "version": "1.0.0"
          }
        }
      }
    }
  }
]

```

3.2. Сводка реального MCP Inspector

Журнал содержит команды, stdout, stderr и exit code. Код 5 здесь означает ожидаемый результат инструмента с `isError: true`; это проверка ошибки, а не падение сервера. Скриншот не требовался, поскольку задание допускает лог.

Случай	Код завершения	Стектрейс
catalog	0	нет
schedule_search success	0	нет
schedule_search error	5	нет
schedule_get success	0	нет
schedule_get error	5	нет
schedule_day success	0	нет
schedule_day error	5	нет
schedule_room success	0	нет
schedule_room error	5	нет

4. Экспериментальная установка и методика

Выбрана указанная пользователем Qwen/Qwen3-0.6B; для поиска — Qwen/Qwen3-Embedding-0.6B того же размера. Обе модели — официальные GGUF Q8_0, запускаются локально через llama.cpp b11429 на CPU, 8 потоков, один слот. ОС Windows; Python 3.13.7; 16 логических процессоров и около 16,89 ГБ RAM. Контекст генерации 8192, эмбедингов 2048; адреса сервисов 127.0.0.1:18080 и :18081. Веса, ревизии и контрольные суммы приведены ниже.

4.1. Часть А: построение выборки и сравнение

Пул состоит из четырёх реально исполняемых инструментов и 96 отвлекающих описаний. 28 близких описаний относятся к экзаменам, консультациям, архиву расписания, аудиториям, календарю и операциям расписания. 68 дальних получены из 17 других доменов по четыре действия. Отвлекающие инструменты не исполнялись. Полный каталог и разметка приведены в приложениях.

Пулы вложенные: первые N записей tools.json, $N \in \{5, 20, 50, 100\}$; четыре целевых инструмента присутствуют в каждом пуле. Близкие и дальние описания перемешаны с seed 20261009 и чередуются. Состав пула фиксирован; порядок показанных кандидатов перемешивается по повтору одинаково для двух условий. Gold выбирается заранее: известный entry_id → get; только аудитория → room; только день для всех курсов → day; фильтр курса, курс вместе с днём или общий поиск → search. Запросов соответственно 8, 8, 7, 7. Общую рубрику получает модель в обоих условиях; правильный ответ конкретного запроса ей не передаётся.

В варианте А модель видит имена и все N описаний. В В эмбединг пользовательского текста сравнивается с эмбедингами **только описаний** внутри текущего пула; выбираются пять максимальных cosine similarity. Вектор имеет размерность 1024, применяется last pooling и нормализация. Затем модель видит имена и описания найденных кандидатов. Ранжирование не использует gold, имена инструментов или исполняемые отвлекающие функции. Для N=5 запросы А/В идентичны, что дополнительно проверено аудитом.

Модель отвечает JSON вида {"tool": "schedule_search"}. Структура ограничена JSON Schema, но значение tool не ограничено enum кандидатов; отсутствующее в каталоге имя считается ошибкой. Это измерение выбора по описаниям, а не испытание встроенного function calling конкретного поставщика. По три запуска каждого запроса и каждого условия: $30 \times 3 \times 4 \times 2 = 720$ вызовов модели.

4.2. Метрики и интервалы

Точность = сумма индикаторов совпадения выбранного имени с gold / 90 для каждой пары N/условие. Recall@5 = число запросов, для которых gold входит в найденные пять / 30. Поиск детерминирован и повторно не увеличивает знаменатель Recall. Средний вход LLM = среднее usage.prompt_tokens по 90 вызовам, включая системный текст, каталог и шаблон чата. Вход query embedding указан отдельно; складывание токенов двух разных моделей служит учётом объёма запросов, а не оценкой единой денежной стоимости.

Для 95%-го percentile bootstrap генерируется 10 000 выборок по 30 **запросов** с возвращением. У каждого выбранного запроса сохраняются все три повтора. В каждой выборке пересчитывается точность; границы — 2,5-й и 97,5-й процентиля. Для В–А одни и те же индексы запросов используются в обоих условиях, разность выражается в процентных пунктах. Повторы не считаются независимыми запросами. Аналогичные дополнительные интервалы для части В ресэмплируют 20 задач, сохраняя три повтора. Seed bootstrap 20261009.

4.3. Часть В: нестабильность, guard и критерий успеха

Экспериментальный `schedule_search` дополнительно принимает `date`. Недельный снимок разворачивается на календарные даты; основной сервер с аргументом `day` остаётся прежним. Задача — найти хотя бы одно занятие нужного курса внутри включительного интервала `start_date...end_date`; начать с заданной даты, разрешены другие даты в интервале. Полные 20 формулировок приведены в приложении С.

Каждый валидный вызов с вероятностью 0,5 вместо записей возвращает `[]` без объяснения. Отказ вычисляется детерминированно по `seed` и номеру вызова; `harness` явно передаёт `fault_handle` вида `seed:ordinal`. Сервер не хранит RNG-сессию. Для одной задачи и повтора во всех трёх условиях совпадает последовательность потенциальных отказов. Вероятность 50% не требует ровно половины отказов в конечной выборке: фактически получилось 31/60 (51,7%) в каждом условии.

Условия: `baseline` — пустой ответ без `guard`; `guard` — тот же инструмент с окном 6 и остановкой до исполнения вызова, который создаст третий идентичный подряд или А-В-А-В; `hint` — без `guard`, вместо пустоты `{"entries": [], "message": "Ничего не найдено; попробуйте другое значение date в разрешённом интервале."}`. В каждом условии $20 \times 3 = 60$ эпизодов, всего 180.

Вызовы сравниваются по имени инструмента и каноническому JSON доменных аргументов. А и В в чередовании должны различаться. Управляющие `fault_handle` и `response_mode` не входят в сигнатуру, иначе новый `ordinal` искусственно скрывал бы повтор. `Guard` проверяет последние шесть вызовов вместе с предлагаемым вызовом. Исполненная петля и заблокированная попытка учитываются отдельно. Предельная длина — 12 шагов; достижение лимита само по себе не объявляется петлёй.

Один шаг — один ответ модели, включая финальный ответ и заблокированное предложение вызова. Токены эпизода — сумма входных и выходных `usage` всех шагов; повторно переданная история входит в расход. Успех требует, чтобы финальные `entry_id` и `date` соответствовали записи, реально полученной из инструмента, нужному курсу и допустимому интервалу. Выдуманная запись и остановка `guard` не считаются успехом.

4.4. Зафиксированные настройки

```
{
  "seed": 20261009,
  "chat_model": "Qwen/Qwen3-0.6B",
  "embedding_model": "Qwen/Qwen3-Embedding-0.6B",
  "quantization": "Q8_0",
  "temperature": 0.7,
  "top_p": 0.8,
  "top_k": 20,
  "min_p": 0,
  "enable_thinking": false,
  "selection_max_tokens": 48,
  "agent_max_tokens": 160,
  "episode_max_steps": 12,
  "guard_window": 6,
  "guard_policy": "stop before third identical or fourth ABAB; lecture implementation unprovided",
  "bootstrap_draws": 10000,
  "bootstrap_unit": "query/task clusters, preserving all three repeats",
  "dataset_hashes": {
    "tools.json": "1de96e7169e2bfb599057ba40f734d68e35f6933915342eb390ddf5b5281d39",
    "queries.json": "c1347e071243a61945e3f6b0449d1a9bee710ad6d24bd596e02c41f3d4026204",
    "loop_tasks.json": "87c056a4999aada5d36370e6019cd060473a21ec9314fdccfa57e84283565b85"
  },
}
```

```

"source_hashes": {
  "analyze.py": "06fe50373b705a843e124869ef63976b4daf2971c1f97c5e1a69670d337a771f",
  "audit_results.py": "887be578fef8caa91bc29184b95a8deb82a55545180e02ea5c9ce6c85243fef",
  "build_data.py": "f575467534b35b2d889029867f45be3de26c94d8f6b72388fda302e125167bc3",
  "core.py": "9d41f11eb7af72c36560a51b41d4264f6cdc9bd40917fa29b15591bec7f9a2ef",
  "download_models.py": "637f1db319016f949abcf3e6cb93456ca07bb1452cd9a0e392a64bbcfb486885",
  "local_api.py": "ad8091eff0e20005a593d3edec1baa79f614de236d2313c958de8a110a4d0f1",
  "run_all.py": "5d5aea85e518c026ee27f20c1959e1edc6baa5932e4325e1a82bc52a2db40048",
  "run_loops.py": "50b5998cb76108516d957bc084bd08860bfa54295244ab97bb6dcfb0f2e0f433",
  "run_selection.py": "3ec4c2c1bd5fc47fceb34332d00b7ee1b77103f533d4d901e47b21d8fcd8f8b",
  "test_experiments.py": "757fb502b46190fcb85d2e1076a08b3e9cfdafe1900c71130f005fbefa4bf3fa",
  "unstable_server.py": "fb601ebe038c49241d98afead54392ae0dee6b0093c2cb8650f232db765620ce"
}
}

```

4.5. Происхождение моделей и контрольные суммы

```

{
  "models": [
    {
      "role": "chat",
      "repo": "Qwen/Qwen3-0.6B-GGUF",
      "revision": "23749fefcc72300e3a2ad315e1317431b06b590a",
      "file": "Qwen3-0.6B-Q8_0.gguf",
      "path": "D:\\lesson-02-mcp-demo\\.runtime\\qwen-experiments\\Qwen3-0.6B-Q8_0.gguf",
      "url": "https://huggingface.co/Qwen/Qwen3-0.6B-GGUF/resolve/23749fefcc72300e3a2ad315e1317431b06b590a/Qwen3-0.6B-Q8_0.gguf",
      "sha256": "9465e63a22add5354d9bb4b99e90117043c7124007664907259bd16d043bb031",
      "quantization": "Q8_0"
    },
    {
      "role": "embedding",
      "repo": "Qwen/Qwen3-Embedding-0.6B-GGUF",
      "revision": "370f27d7550e0def9b39c1f16d3fbba13aa67728",
      "file": "Qwen3-Embedding-0.6B-Q8_0.gguf",
      "path": "D:\\lesson-02-mcp-demo\\.runtime\\qwen-experiments\\Qwen3-Embedding-0.6B-Q8_0.gguf",
      "url": "https://huggingface.co/Qwen/Qwen3-Embedding-0.6B-GGUF/resolve/370f27d7550e0def9b39c1f16d3fbba13aa67728/Qwen3-Embedding-0.6B-Q8_0.gguf",
      "sha256": "06507c7b42688469c4e7298b0a1e16deff06caf291cf0a5b278c308249c3e439",
      "quantization": "Q8_0"
    }
  ],
  "engine": {
    "tag": "b11429",
    "url": "https://github.com/ggml-org/llama.cpp/releases/download/b11429/llama-b11429-bin-win-cpu-x64.zip",
    "sha256": "1283323272b04cd07905816a597a0da810918102de958f4ff6f7bbaa70ed2efe"
  }
}

```

5. Измеренные результаты, сравнение и ограничения

Ниже включён полный отчёт сохранённого анализа экспериментов. Проценты округлены до одного десятичного знака; исходная точность чисел сохранена в `summary.json`.

Эксперимент выбора инструментов и агентных петель

Все результаты получены локальной Qwen/Qwen3-0.6B в официальной Q8_0-квантизации; поиск использует Qwen/Qwen3-Embedding-0.6B Q8_0, last pooling и cosine similarity. Non-thinking mode; temperature=0.7, top_p=0.8, top_k=20, min_p=0. Отвлекающие инструменты не исполняются.

А. Выбор

В каждой строке 30 запросов × 3 повтора. 95%-интервалы: 10 000 бутстрэп-выборок целых запросов, сохраняющих все повторы. Recall@5 вычислен по 30 запросам отдельно от выбора модели. А — все N описаний; В — top-5, найденные только по эмбедингам описаний.

N	Вариант	Точность	95% CI	Recall@5	Вход LLM, токены	Вход с query embedding
5	А	50.0%	33.3% – 66.7%	—	201.3	201.3
5	В	50.0%	33.3% – 66.7%	100.0%	201.3	238.2
20	А	47.8%	31.1% – 64.4%	—	395.3	395.3
20	В	47.8%	30.0% – 65.6%	50.0%	211.9	248.9
50	А	43.3%	27.8% – 58.9%	—	779.3	779.3
50	В	6.7%	0.0% – 16.7%	6.7%	215.7	252.7
100	А	43.3%	31.1% – 55.6%	—	1396.3	1396.3
100	В	0.0%	0.0% – 0.0%	0.0%	212.8	249.8

Однократное построение индекса: 1030 входных токенов embedding-модели; это не повторяется для каждого запроса. Query embedding учитывается как логический онлайн-расход для В; при фактическом прогоне он кэшируется один раз для каждого запроса и переиспользуется во всех N и повторах. В таблице LLM учитываются все входные токены, включая KV-кэшированные: `usage.prompt_tokens`, а не время вычисления.

N	Парная разница точности В – А	95% CI
5	0.0%	0.0% – 0.0%
20	0.0%	-16.7% – 15.6%

N	Парная разница точности B – A	95% CI
50	-36.7%	-51.1% – -22.2%
100	-43.3%	-55.6% – -31.1%

При N=100 сокращение контекста не сохранило точность: правильный инструмент отсутствовал во всех найденных top-5. Это сбой этапа retrieval на данном фиксированном наборе, а не доказательство, что поиск по эмбедингам вообще бесполезен. Проверка embedding-sanity.json подтвердила размерность 1024, уникальность векторов, cosine≈1 для повторно закодированного описания и меньшую близость нерелевантного описания. Бутстрэп-интервал 0–0 при всех нулевых ответах отражает конечную выборку и не доказывает нулевую точность на любых новых запросах.

В. Петли

20 задач × 3 повтора на вариант. baseline — пустой ответ без пояснения; guard — такой же инструмент плюс остановка до третьего одинакового вызова или четвёртого вызова A-B-A-B, окно 6; hint — пояснение вместо пустого ответа, без guard. Алгоритм лекции не предоставлен: использован описанный здесь guard по двум критериям задания, а не подтверждённая копия кода лекции.

Случайный отказ имеет вероятность 50% на каждый вызов. Для одной задачи и повтора одинаковые seed/номер вызова дают одинаковую маску отказов во всех вариантах; сравнение парное. Данные не становятся другими при включении подсказки. Неустойчивый schedule_search реально вызывается через MCP 2026-07-28; fault_handle передаётся явно, сервер не хранит сессию.

Вариант	Петли (исполненные)	Попытка/петля	Средние шаги	Входные токены	Выходные токены	Всего токенов	Успех
baseline	0.0%	0.0%	2.00	510.0	67.2	577.3	48.3%
guard	0.0%	0.0%	2.00	510.1	67.7	577.8	48.3%
hint	0.0%	0.0%	2.00	525.5	64.2	589.8	48.3%

Один шаг — один вызов модели, включая финальный ответ или предложение вызова, заблокированное guard. Токены эпизода — сумма usage всех таких шагов, включая повторно переданную историю. Успех требует финальной ссылки на действительно полученную запись нужного курса внутри разрешённого интервала; выдуманный ответ и остановка guard не считаются успехом. Петля проверяется по каноническому JSON имени инструмента и доменных аргументов. fault_handle и response_mode являются управляющими полями harness и не участвуют в сигнатуре. Ограничение каждого эпизода — 12 шагов; завершение по лимиту не объявляется петлёй автоматически.

Что помогает сильнее

С guard доля исполненных петель — 0.0%, без guard — 0.0%; успех соответственно 48.3% и 48.3%. Подсказка без guard дала 0.0% петель и 48.3% успеха. По доле выполненных задач варианты совпали; решающего преимущества по этой метрике нет. Сравните токены, исполненные петли и попытки петель. Парная разница успеха hint – guard: 0.0%, 95% CI 0.0% – 0.0%. Это исследовательская оценка на 20 задачах; она не устанавливает универсального преимущества на других моделях и доменах. Интервал включает ноль: убедительного преимущества одного варианта по успеху на этом наборе не установлено; направление точечной оценки не равно статистически подтверждённому выигрышу. В baseline заданные паттерны петель не встретились. Этот прогон не позволяет эмпирически оценить устранение петель guard: нет наблюдавшихся петель для устранения. Неуспешный эпизод может закончиться выдуманным финальным ответом вместо повторных вызовов. Нулевой бутстрэп-интервал при нуле наблюдений — особенность percentile bootstrap, а не доказательство нулевого риска на новых задачах. Во всех 180 эпизодах модель сделала один вызов инструмента и сразу финальный ответ. После инъецированного пустого результата она не повторяла поиск и не следовала подсказке сменить date. Guard ни разу не сработал; успех в каждом варианте равен 29/60, то есть равно числу вызовов без отказа. Для оценки защиты именно от петель нужен следующий, отдельно объявленный эксперимент с агентом/задачами, в которых наблюдаются повторные попытки. Эти данные не были заменены подобранными успешными прогонами.

Вариант	Инъецированные отказы / исполненные вызовы	Фактическая доля отказов
baseline	31 / 60	51.7%
guard	31 / 60	51.7%
hint	31 / 60	51.7%

Ограничения и воспроизводимость

Пулы вложенные и фиксированные; все правильные инструменты доступны при любом N. Порядок описаний перемешан по повтору, одинаковое относительное упорядочение используется для A и B. Золотые ответы не передаются модели; общее правило выбора передаётся обоим вариантам. Вывод ограничен JSON-схемой, но имя инструмента не ограничено enum кандидатов: неверное имя считается ошибкой. Это тест выбора по описаниям с JSON-ответом, а не сравнение vendor-specific native function calling. Дистракторы синтетические и размечены; 28 из 96 близки по смыслу. Три повтора не являются 90 независимыми запросами для CI. Сэмплирование с фиксированными seed и KV-кэш может иметь небольшие численные различия между повторными запусками.

Сырые данные: selection.jsonl, retrieval.json, loops.jsonl, loop-mcp-wire.json. Сводные численные значения и парные интервалы: summary.json. Полные запросы модели, ответы, usage и причины завершения сохранены. Параметры моделей, SHA256 весов и движка — model-manifest.json; протокол эксперимента — ../README.md.

Источники: [Qwen3-0.6B](#), [официальный GGUF](#), [Qwen3-Embedding GGUF](#), [llama.cpp API](#).

5.1. Дополнительная детализация ошибок и интервалов

N	Вариант	Правильных / 90	Неверных / отсутствующих имён
5	A	45 / 90	0
5	B	45 / 90	0
20	A	43 / 90	0
20	B	43 / 90	0
50	A	39 / 90	0
50	B	6 / 90	7
100	A	39 / 90	0
100	B	0 / 90	3

Условие	Успех / 60	95% CI успеха	Неподтверждённый финал	Средние вызовы инструмента
baseline	29 / 60	35.0%–61.7%	31	1
guard	29 / 60	35.0%–61.7%	31	1
hint	29 / 60	35.0%–61.7%	31	1

При N=100 вход LLM уменьшается с 1396,3 до 212,8 токена, примерно на 84,8%, но точность падает на 43,3 процентного пункта. Одной экономии контекста недостаточно: до оценки селектора необходимо проверять Recall поиска. Возможное объяснение ошибок — короткие английские описания целевых инструментов и семантически близкие альтернативы при русских запросах; это гипотеза, а не установленная причина. Проверка эмбедингов исключает простую ситуацию одинаковых или нулевых векторов.

Интервалы успеха в B одинаковы: 35,0%–61,7%. Парные разности успеха guard–baseline, hint–baseline и hint–guard равны 0 п.п., bootstrap CI 0–0 на этой выборке. Нулевой интервал отражает совпадение наблюдаемых исходов; он не доказывает эквивалентность методов в генеральной совокупности. У hint средний расход выше baseline на 12,5 токена без прироста успеха. Guard здесь не использовался ни разу, поэтому объявлять его более эффективной защитой на основании малого расхода нельзя.

6. Проверки и независимый аудит

Основные 28 тестов проверяют все четыре инструмента в обоих форматах, ошибки, валидацию схем, discovery, метаданные и сохранение handle после перезапуска. Дополнительные 12 проверяют состав данных и gold, поиск внутри текущего пула, нормализацию вызовов, обнаружение обоих паттернов петель, остановку guard до исполнения, bootstrap по кластерам, парные отказы, изменение только пустого ответа и требование реально наблюдаемой записи для успеха.

Совместный прогон: **40 passed**; failures/errors — 0. Длительность testsuite в сохранённом XML — 11,063 секунды. Отдельная работоспособность guard подтверждена тестами паттернов, но его полезность в агентных эпизодах не установлена.

Аудит повторно проверяет полноту 720 решений и 180 эпизодов, совпадение gold, размеры каталогов, парность seed/порядка, идентичность запросов при N=5, суммы usage, маски отказов, корректность финального успеха и критерии петель. Результат аудита:

```
{
  "selection_rows_verified": 720,
  "episodes_verified": 180,
  "checks": [
    "gold_labels",
    "recomputed_accuracy",
    "candidate_count",
    "paired_seeds_and_order",
    "N5_identical_requests",
    "token_usage_sum",
    "fault_masks",
    "observed_success",
    "loop_definitions",
    "guard_prevents_execution"
  ]
}
```

7. Воспроизведение

Команды PowerShell выполняются из каталога проекта. Для независимого повторения используется новый каталог результатов: исходные наблюдения не перезаписываются. Доступ к API-ключам не требуется; модель запускается локально. Для скачивания пакетов, Inspector и весов нужен интернет. Полный lock-файл рассчитан на использованное окружение Windows/Python 3.13.

```
Set-Location 'D:/lesson-02-mcp-demo/mcp-demo'
py -3.13 -m venv .venv
.\.venv\Scripts\python.exe -m pip install -r requirements-lock.txt
.\.venv\Scripts\python.exe client.py
.\.venv\Scripts\python.exe -m pytest -q -p no:cacheprovider
.\.venv\Scripts\python.exe measure_tokens.py
npm install --prefix .inspector @modelcontextprotocol/inspector@2.10.1
.\.venv\Scripts\python.exe run_inspector.py --cli .inspector/node_modules/@modelcontextprotocol/inspector/clients/launcher/build/index.js
.\.venv\Scripts\python.exe experiments/download_models.py --directory D:/lesson-02-mcp-demo/.runtime/qwen-experiments
.\.venv\Scripts\python.exe experiments/run_all.py --runtime D:/lesson-02-mcp-demo/.runtime/qwen-experiments --output experiments/results-new
```

run_all.py запускает два локальных сервиса моделей и завершает собственные процессы по окончании. При занятом порте останавливается; чужие процессы не завершает. Для сравнения сохраняются фиксированные данные и параметры. При изменении модели, данных или guard нужен отдельный каталог, чтобы не смешать условия.

8. Файлы доказательств

Отчёт содержит все численные результаты и полные перечни примеров. Для проверки на уровне каждого вызова доступны следующие файлы рядом с отчётом:

Файл	Содержание
server.py	Реализация основных инструментов и схем
client.py	Stateless JSON-RPC клиент с _meta
README.md	Документация реализации и три примера токенов
artifacts/wire-log.json	Реальные discovery, tools/list, вызовы и ошибки
artifacts/token-counts.json	Тексты шести ответов и подсчёт токенов
artifacts/inspector-log.json	Девять настоящих запусков Inspector
artifacts/pytest-results.xml	28 основных тестов
experiments/results/pytest-all.xml	40 тестов совместно
experiments/results/selection.jsonl	Все 720 решений с запросами, ответами и usage

Файл	Содержание
experiments/results/retrieval.json	120 результатов поиска: 30 запросов × 4 N
experiments/results/embeddings.json	Векторы каталога и запросов
experiments/results/embedding-sanity.json	Проверка векторов
experiments/results/loops.jsonl	Все 180 эпизодов и их исходы
experiments/results/loop-mcp-wire.json	Настоящий MCP обмен нестабильного инструмента
experiments/results/summary.json	Метрики и bootstrap интервалы без округления
experiments/results/audit.json	Независимая проверка журналов
experiments/results/run-settings.json	Настройки и SHA-256 исходников/данных
experiments/results/model-manifest.json	Ревизии и SHA-256 моделей и runtime
experiments/results/chat-server.log	Журнал генеративной модели
experiments/results/embedding-server.log	Журнал embedding-модели

Приложение А. Полный пул из 100 инструментов

Порядок совпадает с tools.json. Пулы N — первые N строк; «целевой» — исполняемый инструмент, «близкий»/«дальний» — синтетическое отвлекающее описание. Описания представлены дословно, поскольку по ним строился индекс.

№	Имя	Тип	Описание
1	schedule_search	целевой	Search the explicit synthetic schedule snapshot by course and weekday.
2	schedule_get	целевой	Get one schedule entry; obtain entry_id using schedule_search.
3	schedule_day	целевой	List every scheduled class on one supported weekday.
4	schedule_room	целевой	List classes in one supported classroom.
5	exam_get	близкий	Get one examination by examination identifier from the exam timetable.
6	git_list	дальний	Retrieve commit changes for the git domain.
7	devices_get	дальний	Retrieve device firmware versions for the devices domain.
8	exam_search	близкий	Search the synthetic examination timetable by course and exam date; returns exams, not ordinary classes.
9	weather_inspect	дальний	Retrieve air quality readings for the weather domain.
10	issues_list	дальний	Retrieve issue comments for the issues domain.
11	schedule_notifications	близкий	Configure reminders about upcoming classes; changes notification settings.
12	files_search	дальний	Retrieve local file names for the files domain.
13	inventory_inspect	дальний	Retrieve shipment records for the inventory domain.
14	room_details	близкий	Read classroom capacity, facilities and building address by room number.
15	inventory_list	дальний	Retrieve warehouse locations for the inventory domain.
16	weather_get	дальний	Retrieve weather observations for the weather domain.
17	teacher_schedule_search	близкий	Search a specific teacher's teaching workload by teacher and weekday.
18	mail_list	дальний	Retrieve mail folders for the mail domain.
19	devices_search	дальний	Retrieve network device records for the devices domain.
20	schedule_delete	близкий	Delete a class entry from the synthetic course timetable.

№	Имя	Тип	Описание
21	finance_inspect	дальний	Retrieve company fundamentals for the finance domain.
22	images_inspect	дальний	Retrieve image copyright metadata for the images domain.
23	room_availability	близкий	Find free classroom time slots; returns availability rather than scheduled classes.
24	support_inspect	дальний	Retrieve customer contact profiles for the support domain.
25	issues_search	дальний	Retrieve software issue tickets for the issues domain.
26	teacher_schedule_get	близкий	Get a teacher workload entry by workload identifier.
27	mail_inspect	дальний	Retrieve email attachments for the mail domain.
28	analytics_get	дальний	Retrieve traffic metrics for the analytics domain.
29	consultation_get	близкий	Get one teacher consultation appointment by appointment identifier.
30	issues_get	дальний	Retrieve issue details for the issues domain.
31	weather_list	дальний	Retrieve precipitation alerts for the weather domain.
32	archive_schedule_get	близкий	Read one archived schedule entry using an archive record identifier.
33	support_search	дальний	Retrieve customer support cases for the support domain.
34	finance_list	дальний	Retrieve exchange rates for the finance domain.
35	calendar_search	близкий	Search a student's personal calendar appointments by date and title.
36	fitness_inspect	дальний	Retrieve equipment specifications for the fitness domain.
37	music_search	дальний	Retrieve music tracks for the music domain.
38	archive_schedule_room	близкий	List historical classes held in a classroom during a previous semester.
39	issues_inspect	дальний	Retrieve issue labels for the issues domain.
40	maps_search	дальний	Retrieve street addresses for the maps domain.
41	archive_schedule_day	близкий	List all historical course classes on a weekday in an archived semester.
42	travel_list	дальний	Retrieve flight routes for the travel domain.
43	devices_list	дальний	Retrieve device status readings for the devices domain.

№	Имя	Тип	Описание
44	course_enroll	близкий	Enroll a student in a course; changes the enrollment roster.
45	books_search	дальний	Retrieve library books for the books domain.
46	git_get	дальний	Retrieve repository branches for the git domain.
47	schedule_update	близкий	Change the time, weekday or classroom of an existing class entry.
48	finance_search	дальний	Retrieve stock quotes for the finance domain.
49	analytics_search	дальний	Retrieve website traffic events for the analytics domain.
50	schedule_conflicts	близкий	Detect overlapping classroom bookings and conflicting class times.
51	git_search	дальний	Retrieve source code commits for the git domain.
52	weather_search	дальний	Retrieve city weather forecasts for the weather domain.
53	exam_room	близкий	List examinations in a classroom; excludes regular course classes.
54	travel_search	дальний	Retrieve hotel listings for the travel domain.
55	fitness_search	дальний	Retrieve exercise routines for the fitness domain.
56	consultation_room	близкий	List office-hour consultation slots in a classroom.
57	files_inspect	дальний	Retrieve file metadata for the files domain.
58	analytics_list	дальний	Retrieve conversion funnels for the analytics domain.
59	calendar_get	близкий	Read one personal calendar event using an event identifier.
60	files_list	дальний	Retrieve directory listings for the files domain.
61	recipes_search	дальний	Retrieve cooking recipes for the recipes domain.
62	schedule_export	близкий	Export the complete course timetable to an ICS calendar file.
63	support_list	дальний	Retrieve support case messages for the support domain.
64	fitness_list	дальний	Retrieve workout records for the fitness domain.
65	schedule_bus	близкий	Search campus shuttle bus departure times by stop and weekday.
66	music_list	дальний	Retrieve artist biographies for the music domain.

№	Имя	Тип	Описание
67	inventory_get	дальний	Retrieve product stock levels for the inventory domain.
68	exam_day	близкий	List every examination on one weekday in the examination timetable.
69	maps_list	дальний	Retrieve geographic coordinates for the maps domain.
70	books_list	дальний	Retrieve author biographies for the books domain.
71	archive_schedule_search	близкий	Search historical course schedule snapshots from previous semesters.
72	mail_get	дальний	Retrieve email contents for the mail domain.
73	files_get	дальний	Retrieve file contents for the files domain.
74	consultation_search	близкий	Search teacher office-hour appointments by course and weekday.
75	recipes_list	дальний	Retrieve nutrition information for the recipes domain.
76	books_inspect	дальний	Retrieve book reviews for the books domain.
77	schedule_create	близкий	Create a new class in the synthetic course schedule; modifies the timetable.
78	fitness_get	дальний	Retrieve exercise descriptions for the fitness domain.
79	images_get	дальний	Retrieve image dimensions for the images domain.
80	consultation_day	близкий	List teacher consultations and office hours on a weekday.
81	music_inspect	дальний	Retrieve playlists for the music domain.
82	books_get	дальний	Retrieve book editions for the books domain.
83	calendar_day	близкий	List personal calendar appointments on a date, including non-course events.
84	maps_inspect	дальний	Retrieve nearby landmarks for the maps domain.
85	music_get	дальний	Retrieve album metadata for the music domain.
86	course_details	близкий	Read a course syllabus and prerequisites by course identifier; contains no class times.
87	analytics_inspect	дальний	Retrieve audience segments for the analytics domain.
88	support_get	дальний	Retrieve support case details for the support domain.
89	images_search	дальний	Retrieve image asset names for the images domain.

№	Имя	Тип	Описание
90	finance_get	дальний	Retrieve historical market prices for the finance domain.
91	images_list	дальний	Retrieve image color palettes for the images domain.
92	maps_get	дальний	Retrieve walking directions for the maps domain.
93	inventory_search	дальний	Retrieve warehouse products for the inventory domain.
94	mail_search	дальний	Retrieve email messages for the mail domain.
95	recipes_inspect	дальний	Retrieve cooking techniques for the recipes domain.
96	travel_get	дальний	Retrieve hotel room types for the travel domain.
97	recipes_get	дальний	Retrieve recipe ingredients for the recipes domain.
98	git_inspect	дальний	Retrieve repository tags for the git domain.
99	travel_inspect	дальний	Retrieve airport information for the travel domain.
100	devices_inspect	дальний	Retrieve device configuration backups for the devices domain.

Приложение В. Все 30 запросов с эталонным инструментом

ID	Запрос	Правильный инструмент
q01	Найди занятия курса agents в текущем учебном расписании.	schedule_search
q02	Покажи все занятия курса python из снимка schedule-v1.	schedule_search
q03	Какие пары по databases стоят в расписании?	schedule_search
q04	Найди занятия agents, которые проходят в среду.	schedule_search
q05	Проверь расписание курса python на вторник.	schedule_search
q06	Выведи все записи текущего расписания без фильтров.	schedule_search
q07	Нужен поиск пар по курсу agents и дню monday.	schedule_search
q08	Есть ли у databases занятия в понедельник?	schedule_search
q09	Открой занятие с идентификатором agents-mon.	schedule_get
q10	Получить одну запись расписания: python-tue.	schedule_get
q11	Покажи подробности занятия databases-wed из schedule-v1.	schedule_get
q12	Мне нужна конкретная пара agents-wed, её id уже известен.	schedule_get
q13	Прочитай запись agents-mon без поиска других занятий.	schedule_get
q14	У меня есть entry_id python-tue. Покажи соответствующее занятие.	schedule_get
q15	По ключу databases-wed получить занятие текущего расписания.	schedule_get
q16	Верни подробную запись пары agents-wed по её идентификатору.	schedule_get
q17	Выведи все учебные пары в понедельник, независимо от курса.	schedule_day
q18	Какие занятия текущего расписания проходят во вторник? Нужны все курсы.	schedule_day
q19	Покажи полное расписание учебных занятий на среду.	schedule_day
q20	Мне нужен список всех пар на monday из schedule-v1.	schedule_day
q21	Собери все занятия вторника, без фильтра по предмету.	schedule_day

ID	Запрос	Правильный инструмент
q22	Что стоит в учебном расписании на wednesday по всем курсам?	schedule_day
q23	Список обычных учебных занятий понедельника целиком.	schedule_day
q24	Какие учебные пары запланированы в аудитории 314?	schedule_room
q25	Покажи занятия в кабинете 210 из текущего расписания.	schedule_room
q26	Все запланированные занятия аудитории 115.	schedule_room
q27	Нужен список пар, проходящих в комнате 314, по всем дням.	schedule_room
q28	Что за учебные занятия стоят для аудитории 210 в schedule-v1?	schedule_room
q29	Перечисли пары в кабинете 115 без проверки свободных мест.	schedule_room
q30	Для аудитории 314 получи запланированные занятия всех курсов.	schedule_room

Приложение С. Все 20 задач части В

Каждая задача выполнялась трижды в каждом из трёх условий. Handle для всех задач — schedule-v1.

ID	Задача
t01	Найди хотя бы одно занятие курса agents между 2026-10-12 и 2026-10-19 включительно. Начни с date=2026-10-12. Верни найденные entry_id и date; используй только данные инструмента.
t02	Найди хотя бы одно занятие курса python между 2026-10-13 и 2026-10-20 включительно. Начни с date=2026-10-13. Верни найденные entry_id и date; используй только данные инструмента.
t03	Найди хотя бы одно занятие курса databases между 2026-10-14 и 2026-10-21 включительно. Начни с date=2026-10-14. Верни найденные entry_id и date; используй только данные инструмента.
t04	Найди хотя бы одно занятие курса agents между 2026-10-19 и 2026-10-26 включительно. Начни с date=2026-10-19. Верни найденные entry_id и date; используй только данные инструмента.
t05	Найди хотя бы одно занятие курса python между 2026-10-20 и 2026-10-27 включительно. Начни с date=2026-10-20. Верни найденные entry_id и date; используй только данные инструмента.
t06	Найди хотя бы одно занятие курса databases между 2026-10-21 и 2026-10-28 включительно. Начни с date=2026-10-21. Верни найденные entry_id и date; используй только данные инструмента.
t07	Найди хотя бы одно занятие курса agents между 2026-10-26 и 2026-11-02 включительно. Начни с date=2026-10-26. Верни найденные entry_id и date; используй только данные инструмента.
t08	Найди хотя бы одно занятие курса python между 2026-10-27 и 2026-11-03 включительно. Начни с date=2026-10-27. Верни найденные entry_id и date; используй только данные инструмента.
t09	Найди хотя бы одно занятие курса databases между 2026-10-28 и 2026-11-04 включительно. Начни с date=2026-10-28. Верни найденные entry_id и date; используй только данные инструмента.
t10	Найди хотя бы одно занятие курса agents между 2026-11-02 и 2026-11-09 включительно. Начни с date=2026-11-02. Верни найденные entry_id и date; используй только данные инструмента.
t11	Найди хотя бы одно занятие курса python между 2026-11-03 и 2026-11-10 включительно. Начни с date=2026-11-03. Верни найденные entry_id и date; используй только данные инструмента.
t12	Найди хотя бы одно занятие курса databases между 2026-11-04 и 2026-11-11 включительно. Начни с date=2026-11-04. Верни найденные entry_id и date; используй только данные инструмента.
t13	Найди хотя бы одно занятие курса agents между 2026-11-09 и 2026-11-16 включительно. Начни с date=2026-11-09. Верни найденные entry_id и date; используй только данные инструмента.
t14	Найди хотя бы одно занятие курса python между 2026-11-10 и 2026-11-17 включительно. Начни с date=2026-11-10. Верни найденные entry_id и date; используй только данные инструмента.
t15	Найди хотя бы одно занятие курса databases между 2026-11-11 и 2026-11-18 включительно. Начни с date=2026-11-11. Верни найденные entry_id и date; используй только данные инструмента.
t16	Найди хотя бы одно занятие курса agents между 2026-11-16 и 2026-11-23 включительно. Начни с date=2026-11-16. Верни найденные entry_id и date; используй только данные инструмента.
t17	Найди хотя бы одно занятие курса python между 2026-11-17 и 2026-11-24 включительно. Начни с date=2026-11-17. Верни найденные entry_id и date; используй только данные инструмента.
t18	Найди хотя бы одно занятие курса databases между 2026-11-18 и 2026-11-25 включительно. Начни с date=2026-11-18. Верни найденные entry_id и date; используй только данные инструмента.
t19	Найди хотя бы одно занятие курса agents между 2026-11-23 и 2026-11-30 включительно. Начни с date=2026-11-23. Верни найденные entry_id и date; используй только данные инструмента.
t20	Найди хотя бы одно занятие курса python между 2026-11-24 и 2026-12-01 включительно. Начни с date=2026-11-24. Верни найденные entry_id и date; используй только данные инструмента.

Приложение D. Полные входные схемы четырёх основных инструментов

Схемы получены из каталога фактического сервера. На верхнем уровне дополнительных полей нет; описания есть у всех параметров. `entry_id` открыт, остальные закрытые доменные множества используют `enum`.

`schedule_search`

```
{
  "properties": {
    "schedule_handle": {
      "description": "Explicit immutable schedule snapshot handle.",
      "title": "Schedule Handle",
      "type": "string",
      "enum": [
        "schedule-v1"
      ]
    },
    "course": {
      "default": "all",
      "description": "Course filter; all selects every course.",
      "enum": [
        "all",
        "agents",
        "python",
        "databases"
      ],
      "title": "Course",
      "type": "string"
    },
    "day": {
      "default": "all",
      "description": "Weekday filter; all selects every day.",
      "enum": [
        "all",
        "monday",
        "tuesday",
        "wednesday"
      ],
      "title": "Day",
      "type": "string"
    },
    "response_format": {
      "default": "concise",
      "description": "Amount of detail in the response.",
      "enum": [
        "concise",
        "detailed"
      ],
      "title": "Response Format",
      "type": "string"
    }
  }
}
```

```

    },
    "required": [
        "schedule_handle"
    ],
    "title": "schedule_searchArguments",
    "type": "object",
    "additionalProperties": false,
    "description": "Search the explicit synthetic schedule snapshot by course and weekday."
}

```

schedule_get

```

{
  "properties": {
    "schedule_handle": {
      "description": "Explicit immutable schedule snapshot handle.",
      "title": "Schedule Handle",
      "type": "string",
      "enum": [
        "schedule-v1"
      ]
    },
    "entry_id": {
      "description": "Entry identifier returned by schedule_search.",
      "maxLength": 64,
      "minLength": 1,
      "title": "Entry Id",
      "type": "string"
    },
    "response_format": {
      "default": "concise",
      "description": "Amount of detail in the response.",
      "enum": [
        "concise",
        "detailed"
      ],
      "title": "Response Format",
      "type": "string"
    }
  },
  "required": [
    "schedule_handle",
    "entry_id"
  ],
  "title": "schedule_getArguments",
  "type": "object",
  "additionalProperties": false,
  "description": "Get one schedule entry; obtain entry_id using schedule_search."
}

```

schedule_day

```
{
  "properties": {
    "schedule_handle": {
      "description": "Explicit immutable schedule snapshot handle.",
      "title": "Schedule Handle",
      "type": "string",
      "enum": [
        "schedule-v1"
      ]
    },
    "day": {
      "description": "Weekday to inspect.",
      "enum": [
        "monday",
        "tuesday",
        "wednesday"
      ],
      "title": "Day",
      "type": "string"
    },
    "response_format": {
      "default": "concise",
      "description": "Amount of detail in the response.",
      "enum": [
        "concise",
        "detailed"
      ],
      "title": "Response Format",
      "type": "string"
    }
  },
  "required": [
    "schedule_handle",
    "day"
  ],
  "title": "schedule_dayArguments",
  "type": "object",
  "additionalProperties": false,
  "description": "List every scheduled class on one supported weekday."
}
```

schedule_room

```
{
  "properties": {
    "schedule_handle": {
      "description": "Explicit immutable schedule snapshot handle.",
      "title": "Schedule Handle",
```

```

    "type": "string",
    "enum": [
      "schedule-v1"
    ],
  },
  "room": {
    "description": "Supported classroom number.",
    "enum": [
      "314",
      "210",
      "115"
    ],
    "title": "Room",
    "type": "string"
  },
  "response_format": {
    "default": "concise",
    "description": "Amount of detail in the response.",
    "enum": [
      "concise",
      "detailed"
    ],
    "title": "Response Format",
    "type": "string"
  }
},
"required": [
  "schedule_handle",
  "room"
],
"title": "schedule_roomArguments",
"type": "object",
"additionalProperties": false,
"description": "List classes in one supported classroom."
}

```

Общая выходная схема успешного результата

Ошибка передаётся как `isError` с текстовым `JSON code/message/hint`. Успешный результат содержит совпадающие `content` и `structuredContent`; это учтено при измерении полного размера.

```

{
  "type": "object",
  "description": "Synthetic schedule query result.",
  "additionalProperties": false,
  "required": [
    "schedule_handle",
    "synthetic",
    "entries"
  ],

```

```

"properties": {
  "schedule_handle": {
    "type": "string",
    "description": "Immutable snapshot handle.",
    "enum": [
      "schedule-v1"
    ]
  },
  "synthetic": {
    "type": "boolean",
    "enum": [
      true
    ],
    "description": "Data are invented for this exercise."
  },
  "source": {
    "type": "string",
    "description": "Fixture provenance.",
    "enum": [
      "fixture:schedule-v1"
    ]
  },
  "timezone": {
    "type": "string",
    "description": "Timezone of the listed class times.",
    "enum": [
      "Europe/Moscow"
    ]
  },
  "note": {
    "type": "string",
    "description": "Disclaimer about the synthetic dataset."
  },
  "entries": {
    "type": "array",
    "description": "Matching classes; empty when no classes match.",
    "items": {
      "type": "object",
      "description": "One class; detailed mode adds course, end and teacher.",
      "additionalProperties": false,
      "required": [
        "id",
        "day",
        "start",
        "room"
      ],
      "properties": {
        "id": {
          "type": "string",
          "description": "Entry identifier for schedule_get."
        },
        "course": {
          "type": "string",

```


Приложение Е. Источники

Протокольная реализация опирается на [спецификацию MCP 2026-07-28](#), [описание изменений версии](#) и [Python SDK](#). Режим и коды Inspector описаны в [официальной документации CLI](#).

Модели: [Qwen3-0.6B](#), [официальный GGUF генеративной модели](#), [официальный GGUF Qwen3-Embedding-0.6B](#). Сервер локального выполнения: [llama.cpp server](#). Источник всех экспериментальных чисел — собственные журналы проекта, перечисленные в разделе 8.